Inside the Machine

Eine interaktive Datenstory, in der die KI sich selbst vermisst

Wayan Schmidt, DAISY (HSD Düsseldorf), Visual Analytics (Summer Edition), 2026

1. Problem und Fallstudie

Künstliche Intelligenz wird oft über Einzelbeispiele diskutiert. Diese Fallstudie verbindet dagegen fünf offene Datenbestände zu einer Leitfrage: **Wie sieht das KI-Ökosystem aus, wenn man es aus seinen eigenen Daten rekonstruiert, und erkennt ein Mensch die Maschine am Ende noch?** Die Datenstory richtet sich an Leserinnen und Leser ohne Fachvorwissen. Ihr kritischer Kern ist die Spannung zwischen dem messbaren Wachstum von Rechenleistung, Forschung und Modellfamilien einerseits und begrenzter menschlicher Kontrolle andererseits. Die Plattformdaten werden nicht als vollständiger Zensus behandelt, sondern als selektive Spuren von Epoch AI, arXiv, OpenAlex, Hugging Face, WildChat und HC3.

2. Methode und Visualisierungstechnik

Die Konzeption folgt Munzners *What/Why/How* und dem Nested Model (Munzner 2014, 2009). Die Tasks sind nach Brehmer und Munzner (2013) formuliert. Die Story nutzt ein geführtes Scrollytelling mit freien Explorationspunkten, also einen Wechsel von author-driven zu reader-driven (Segel und Heer 2010).

Akt 1, Compute. 466 Modelle ab 2010 werden als Streudiagramm über Zeit und logarithmische Training-FLOP gezeigt. Position auf gemeinsamen Skalen trägt die quantitative Aussage; Farbe wiederholt die Magnitude. Eine Frontier verbindet die jeweils rechenintensivsten Modelle. Task: *discover trend, identify outliers*.

Akt 2, Forschung. 477.807 arXiv-Paper werden als Canvas-Punktwolke dargestellt. Die Lage ist aus TF-IDF und Truncated SVD abgeleitet und bedeutet Vokabularähnlichkeit, nicht semantische Wahrheit. Scrollen verändert das Jahr, ein Klick selektiert eines von acht Feldern und öffnet dessen meistzitierte Paper. Task: *summarize, explore, select*.

Akt 3, Modellfamilien. Aus 528.311 deklarierten Abstammungskanten entstehen 160 Familien-Hubs und 38.385 Kindersterne. Größe kodiert Downloads, Helligkeit Aktualität und Farbe den Relationstyp. Zoom und Details-on-demand unterstützen das Nachverfolgen von Lineage. Task: *explore topology, navigate*.

Akt 4, Nutzung. 837.989 WildChat-Gespräche werden nicht auf einer Karte, sondern als reorderbare Matrix mit 53 Länderzeilen gezeigt. Die IP-basierte Länderzuordnung rechtfertigt keine präzise Geo-

grafie; Fläche würde zudem nichts messen. Volumen nutzt Länge am gemeinsamen Nullpunkt, Themen ein gestapeltes Band und der Anteil oberhalb der offengelegten Moderationsschwelle Position. Die Sortierung ist selbst die Analyse, nach Bertins *matrice ordonnable*. Animation dient ausschließlich der Object Constancy (Heer und Robertson 2007). Der zentrale Befund ist eine Widerlegung: Die Korrelation zwischen Rollenspiel und Graubereich fällt von r = 0,71 auf r = 0,24, wenn zwei datenbestimmte Hebelpunkte entfernt werden.

Akt 5, Urteil. Zwölf Entscheidungen aus HC3-Texten sowie realen und synthetischen Bildern messen den Leser als anekdotisches Finale. Das Ergebnis wird getrennt nach Text und Bild gezeigt. Ergänzend ordnen kontrollierte Studien die menschliche Erkennung ein; einfache Tipps verbessern sie nicht signifikant (Bray et al. 2023). Über alle Akte gilt: Position und Länge werden für quantitative Vergleiche priorisiert (Cleveland und McGill 1984), Farbe typisiert oder ordnet passend zum Attribut (Ware 2013), und nicht-datentragende Tinte bleibt sparsam (Tufte 1983). Interaktionen entsprechen insbesondere *select, explore, reconfigure, filter* und *connect* (Yi et al. 2007).

3. Vorläufige Evaluation

Die Evaluation folgt den vier Ebenen des Nested Model. **Domain:** Die Zwischenfassung wurde im Kurs präsentiert; umgesetzt wurden das Schließen der Datenlücke 2022 bis 2026, klickbare Top-Paper, die Abkehr von der Weltkarte und ein klarerer Übergang zum Finale. **Abstraction:** Datentyp und Task stehen in jedem Akt; die Themenheuristik erreicht gegen 400 separat durch ein LLM annotierte Prompts $\kappa = 0{,}50$, Accuracy 0,555 und Macro-F1 0,53. **Encoding/Interaction:** Tastaturpfad, Reduced Motion und Screenreader-Tabellen wurden automatisiert und manuell geprüft. **Algorithm:** 160 Unit-Tests sowie Browserprüfungen laufen ohne Fehler; gemessen wurden 51 fps für Akt 2, 38 fps für Akt 3 und 60 fps für Akt 4 im Headless-Chromium-Test. Ein kontrollierter Lesbarkeitstest mit weiteren Personen bleibt als nächste externe Evaluation offen.

4. Diskussion und Schluss

Die Stärke der Arbeit liegt in der Verbindung von Datenabstraktion, visueller Kodierung und kritischer Begrenzung. Abgeleitete Positionen, Heuristiken, IP-Geografie und Downloadzahlen werden im Interface als solche bezeichnet. Grenzen bleiben: Plattformselektion, fehlende Modelle ohne deklarierte Herkunft, nicht zufällig gezogene Gesprächsbelege, zu schmale Konfidenzintervalle auf Gesprächsebene und ein desktop-first Layout.

Die Leitfrage endet deshalb nicht mit einem Erkennungsrezept. Die Daten zeigen zugleich Wachstum, Verflechtung und Unsicherheit: Compute steigt über zwölf Größenordnungen, Modellfamilien vermeh-

ren sich, und scheinbar klare Länderregeln können an zwei Punkten hängen. Herkunft ist damit belastbarer als ein einzelnes sichtbares Merkmal.

5. KI-Nutzung

Claude Code und Codex unterstützten technische Implementierung, Recherche, Tests und strukturierte Gegenprüfung. Problemrahmung, Datensatzauswahl, analytische Fragen, Visualisierungsentscheidungen, Interpretation, iterative Kritik und finale Abnahme wurden durch den Bearbeiter verantwortet. Übernommene Ergebnisse wurden gegen Quelldaten sowie durch Build-, Unit-, Browser- und visuelle Tests geprüft. Das vollständige, nach Arbeitsphasen geordnete Protokoll liegt unter `supplemental/ki-nutzung.md`.

6. Literatur und Daten

Visualisierungstheorie. Bertin, J. (1967): *Sémiologie graphique. Les diagrammes, les réseaux, les cartes*. Gauthier-Villars. Brehmer, M.; Munzner, T. (2013): A Multi-Level Typology of Abstract Visualization Tasks. *IEEE Transactions on Visualization and Computer Graphics*, 19(12), 2376–2385. DOI: 10.1109/TVCG.2013.124. Cleveland, W. S.; McGill, R. (1984): Graphical Perception: Theory, Experimentation, and Application to the Development of Graphical Methods. *Journal of the American Statistical Association*, 79(387), 531–554. DOI: 10.1080/01621459.1984.10478080. Heer, J.; Robertson, G. (2007): Animated Transitions in Statistical Data Graphics. *IEEE Transactions on Visualization and Computer Graphics*, 13(6), 1240–1247. DOI: 10.1109/TVCG.2007.70539. Munzner, T. (2009): A Nested Model for Visualization Design and Validation. *IEEE Transactions on Visualization and Computer Graphics*, 15(6), 921–928. DOI: 10.1109/TVCG.2009.111. Munzner, T. (2014): *Visualization Analysis and Design*. CRC Press. Segel, E.; Heer, J. (2010): Narrative Visualization: Telling Stories with Data. *IEEE Transactions on Visualization and Computer Graphics*, 16(6), 1139–1148. DOI: 10.1109/TVCG.2010.179. Tufte, E. R. (1983): *The Visual Display of Quantitative Information*. Graphics Press. Ware, C. (2013): *Information Visualization: Perception for Design*, 3. Auflage. Morgan Kaufmann. Yi, J. S.; Kang, Y. A.; Stasko, J. T.; Jacko, J. A. (2007): Toward a Deeper Understanding of the Role of Interaction in Information Visualization. *IEEE Transactions on Visualization and Computer Graphics*, 13(6), 1224–1231. DOI: 10.1109/TVCG.2007.70515.

Daten und empirische Quellen. Bray, S. D.; Johnson, S. D.; Kleinberg, B. (2023): Testing Human Ability to Detect ‘Deepfake’ Images of Human Faces. *Journal of Cybersecurity*, 9(1), tyad011. DOI: 10.1093/cybsec/tyad011. Clement, C. B.; Bierbaum, M.; O'Keeffe, K. P.; Alemi, A. A. (2019): On the Use of ArXiv as a Dataset. arXiv:1905.00075. Epoch AI (2026): *Data on AI Models*.

https://epoch.ai/data/ai-models, abgerufen 26.07.2026. Guo, B.; Zhang, X.; Wang, Z.; Jiang, M.; Nie, J.; Ding, Y.; Yue, J.; Wu, Y. (2023): How Close Is ChatGPT to Human Experts? Comparison Corpus, Evaluation, and Detection. arXiv:2301.07597. Natural Earth (2026): *Admin 0 Countries, 1:110m*, Version 5.2.0-pre. https://www.naturalearthdata.com, abgerufen 26.07.2026. Priem, J.; Piwowar, H.; Orr, R. (2022): OpenAlex: A Fully-Open Index of Scholarly Works, Authors, Venues, Institutions, and Concepts. arXiv:2205.01833. Rawal, P. (2025): *AI-vs-Real Dataset*. https://huggingface.co/datasets/Parveshiiii/AI-vs-Real, abgerufen 26.07.2026. Zhao, W.; Ren, X.; Hessel, J.; Cardie, C.; Choi, Y.; Deng, Y. (2024): WildChat: 1M ChatGPT Interaction Logs in the Wild. *ICLR 2024*, arXiv:2405.01470. arXiv (2026): *OAI-PMH Metadata Service*, Sets `cs` und `stat`. https://oaipmh.arxiv.org/oai, abgerufen 11.07.2026. *librarian-bots/model_cards_with_metadata*. https://huggingface.co/datasets/librarian-bots/model_cards_with_metadata, abgerufen 26.07.2026; auf der Datensatzkarte ist keine Lizenz angegeben.

Weitere Inhaltsquellen des Finales. Diel, A.; Lalgi, T.; Schröter, I. C.; MacDorman, K. F.; Teufel, M.; Bäuerle, A. (2024): Human Performance in Detecting Deepfakes: A Systematic Review and Meta-Analysis of 56 Papers. *Computers in Human Behavior Reports*, 16, 100538. DOI: 10.1016/j.chbr.2024.100538. Kamali, N.; Nakamura, K.; Kumar, A.; Chatzimparmpas, A.; Hullman, J.; Groh, M. (2025): Characterizing Photorealism and Artifacts in Diffusion Model-Generated Images. *CHI 2025*. DOI: 10.1145/3706598.3713962. Köbis, N. C.; Doležalová, B.; Soraperra, I. (2021): Fooled Twice: People Cannot Detect Deepfakes but Think They Can. *iScience*, 24(11), 103364. DOI: 10.1016/j.isci.2021.103364. Nightingale, S. J.; Farid, H. (2022): AI-Synthesized Faces Are Indistinguishable from Real Faces and More Trustworthy. *PNAS*, 119(8), e2120481119. DOI: 10.1073/pnas.2120481119. Lukas, N.; Diaa, A.; Fenaux, L.; Kerschbaum, F. (2024): Leveraging Optimization for Adaptive Attacks on Image Watermarks. *ICLR 2024*. Müller, A.; Lukovnikov, D.; Thietke, J.; Fischer, A.; Quiring, E. (2025): Black-Box Forgery Attacks on Semantic Watermarks for Diffusion Models. *CVPR 2025*, 20937–20946. Rijsbosch, B.; van Dijck, G.; Kollnig, K. (2025): Missing the Mark: Adoption of Watermarking for Generative AI Systems in Practice and Implications under the New EU AI Act. arXiv:2503.18156. Europäische Union (2024): Verordnung (EU) 2024/1689, insbesondere Art. 50 und 113. *Amtsblatt der Europäischen Union*, 12.07.2024. OpenAI (2025): *Sora 2 System Card*, 30.09.2025. https://openai.com/index/sora-2-system-card/. Prakash, P. (2024): A Deepfake ‘CFO’ Tricked the British Design Firm Behind the Sydney Opera House in $25 Million Scam. *Fortune Europe*, 17.05.2024. South China Morning Post (2024): UK Multinational Arup Confirmed as Victim

of HK$200 Million Deepfake Scam, 17.05.2024. Weitere Abrufdaten und Lizenzen stehen in `data/QUELLEN.md`.